

0.1 代表的な準ニュートン更新則

B_k, s_k, y_k が与えられたとき、セカント条件を満たす B_{k+1} を与える更新則は多数存在します。ここでは代表的なものをその導出とともに示します [3]。本小節に限り、簡潔さのため B_k, B_{k+1}, s_k, y_k をそれぞれ $B, \bar{B}, s, y$ と略記します。

0.1.1 Broyden 更新

Broyden 更新 は最も古くから知られる更新則の一つですが、準ニュートン法の文脈では、対称性を保たないため実用上はあまり用いられません。歴史的な観点もふまえ、簡潔に紹介します。更新則は次で与えられます。

$$\bar{B}_{\text{Broyden}} := B + \frac{(y - Bs)s^\top}{s^\top s}.$$

導出 単純な構造的仮定からこの公式を導出します [3, Section 4]。

Proposition 1. $\bar{B}$ がセカント条件

$$\bar{B}s = y,$$

と制約

$$\bar{B}z = Bz \quad \text{for all } z \in \mathbb{R}^n \text{ such that } z^\top s = 0.$$

を満たすと仮定します。このとき $\bar{B}$ は一意に定まり、 $\bar{B}_{\text{Broyden}}$ に一致します。

Proof. ベクトル s と s の直交補空間の基底は $\mathbb{R}^n$ の基底を成します。 $\bar{B}$ の条件はこの基底に対する $\bar{B}$ の作用を完全に決定するため、 $\bar{B}$ は一意に定まります。

ここで $\bar{B}_{\text{Broyden}}$ が課された条件を満たすことを示します。 $z^\top s = 0$ を満たす任意のベクトル z を取ります。このとき、次を得ます。

$$\begin{aligned} \bar{B}_{\text{Broyden}}s &= \left(B + \frac{(y - Bs)s^\top}{s^\top s} \right) s = Bs + (y - Bs) = y, \\ \bar{B}_{\text{Broyden}}z &= \left(B + \frac{(y - Bs)s^\top}{s^\top s} \right) z = Bz + (z^\top s) \frac{y - Bs}{s^\top s} = Bz. \end{aligned}$$

したがって、 $\bar{B}_{\text{Broyden}}$ は課された条件を満たします。よって、一意性より $\bar{B} = \bar{B}_{\text{Broyden}}$ となります。 □

Broyden 更新は、フロベニウスノルムにおける最小変化更新としても特徴づけられます。

Proposition 2 ([3, Theorem 4.1]). $B \in \mathbb{R}^{n \times n}$, $y \in \mathbb{R}^n$, $s \in \mathbb{R}^n \setminus \{0\}$ が与えられているとき、行列 $\bar{B}_{\text{Broyden}}$ は以下の最適化問題の一意解である。

$$\begin{aligned} &\underset{\bar{B} \in \mathbb{R}^{n \times n}}{\text{minimize}} && \|\bar{B} - B\|_F \\ &\text{subject to} && \bar{B}s = y. \end{aligned}$$

Proof. 関数 $\bar{B} \mapsto \|\bar{B} - B\|_F^2$ を最適化すると考えてよく、これは $\mathbb{R}^{n \times n}$ 上で凸です。制約集合

$$\{\bar{B} \in \mathbb{R}^{n \times n} : \bar{B}s = y\}$$

はアフィン集合であり凸です。よって、この最適化問題は高々一つの最小解しか持ちません。

$\bar{B}_{\text{Broyden}}$ が実際に最小解であることを示します。制約 $\bar{B}s = y$ を満たす任意の $\bar{B}$ に対して

$$\|\bar{B}_{\text{Broyden}} - B\|_F^2 = \left\| (\bar{B} - B) \frac{ss^\top}{s^\top s} \right\|_F^2 \leq \|\bar{B} - B\|_F^2.$$

ここでフロベニウスノルムの劣乗法性と $\|ss^\top / (s^\top s)\|_F = 1$ を用いました。よって $\bar{B} = \bar{B}_{\text{Broyden}}$ となり、主張が得られます。 □

この更新則は、対称性を保たないという点に注意してください。以下では、その点を改善した代表的な準ニュートン更新則を紹介します。

0.1.2 Symmetric Rank-One (SR1) 更新

対称ランク 1 (SR1) 更新 [9] は更新過程で対称性を維持する基本的な準ニュートン法です。更新則は次で与えられます。

$$\bar{B}_{\text{SR1}} := B + \frac{(y - Bs)(y - Bs)^\top}{(y - Bs)^\top s}.$$

導出 SR1 更新を導出するため、更新行列 $\bar{B}$ をランク 1 更新として構成します。すなわち、あるベクトル $z \in \mathbb{R}^n$ に対して、次が満たされると仮定します。

$$\bar{B}_{\text{SR1}} = B + zz^\top.$$

セカント条件 $\bar{B}_{\text{SR1}}s = y$ を満たすためには、 $z^\top s \neq 0$ のとき、次が必要となります。

$$Bs + zz^\top s = y.$$

整理すると、

$$z = \frac{y - Bs}{z^\top s}.$$

$z^\top s$ を決めるために s との内積を取ると、

$$z^\top s = \frac{(y - Bs)^\top s}{z^\top s}.$$

この式を整理すると次の関係が得られます。

$$(z^\top s)^2 = (y - Bs)^\top s.$$

従って、

$$\bar{B}_{\text{SR1}} = B + zz^\top = B + \frac{(y - Bs)(y - Bs)^\top}{(z^\top s)^2} = B + \frac{(y - Bs)(y - Bs)^\top}{(y - Bs)^\top s}.$$

よって、SR1 更新が導出されました。

補足 SR1 更新は $(y - Bs)^\top s \neq 0$ であることを前提としています。 $(y - Bs)^\top s = 0$ のとき分母が零となり、実用上は更新をスキップすることが多いです。

0.1.3 Powell Symmetric Broyden (PSB) 更新

Powell Symmetric Broyden (PSB) 更新 [2, 4, 8] も準ニュートン更新則の一つで、更新則は次で与えられます。

$$\bar{B}_{\text{PSB}} = B + \frac{(y - Bs)s^\top + s(y - Bs)^\top}{s^\top s} - \frac{s^\top (y - Bs)}{(s^\top s)^2} ss^\top$$

導出 SR1 更新では B に $zz^\top$ を加えることで $\bar{B}$ を得ていました。代わりに、あるベクトル $c \in \mathbb{R}^n$ に対して、非対称なランク 1 更新 $zc^\top$ を考えることができます。そして最後に結果を対称化します。 $c^\top s \neq 0$ と仮定し、 $Bs + zc^\top s = y$ から z を

$$z = \frac{y - Bs}{c^\top s}$$

と導き、これを用いて次の非対称更新を行います。

$$C_1 := B + \frac{(y - Bs)c^\top}{c^\top s}.$$

C_1 は一般に対称でないため、これを対称化します。

$$C_2 = \frac{C_1 + C_1^\top}{2}.$$

しかし、対称化された行列 C_2 はセカント条件 $C_2 s = y$ を満たさない場合があります。そこでこの過程を反復することを考えます。

$$\begin{cases} C_0 = B \\ C_{2l+1} = C_{2l} + \frac{(y - C_{2l}s)c^\top}{c^\top s} & (\text{asymmetric update}) \\ C_{2l+2} = \frac{C_{2l+1} + C_{2l+1}^\top}{2} & (\text{symmetrization}) \end{cases}$$

重要な結果として、列 $\{C_{2l}\}_{l=0}^\infty$ はセカント条件を満たす対称行列に収束します。次の命題ではそれを示します。

Proposition 3 ([3, Lemma 7.2]). 行列の列 $\{C_l\}_{l=0}^\infty$ は収束し、その極限は次で与えられる。

$$\lim_{l \rightarrow \infty} C_l = C_\infty := B + \frac{(y - Bs)c^\top + c(y - Bs)^\top}{c^\top s} - \frac{(y - Bs)^\top s}{(c^\top s)^2} cc^\top.$$

Proof. まず偶数番目の部分列を解析します。 $t = 0, 1, 2, \dots$ に対し、次のように定義します。

$$G_t := C_{2t}.$$

構成方法より各 G_t は対称です。定義から次を得ます。

$$G_{t+1} = G_t + \frac{1}{2c^\top s} \left((y - G_t s)c^\top + c(y - G_t s)^\top \right).$$

また、セカント条件に対する誤差ベクトルを次で導入します。

$$w_t := y - G_t s.$$

このとき、

$$G_{t+1} = G_t + \frac{1}{2c^\top s} (w_t c^\top + c w_t^\top).$$

上式を w_t の定義に代入すると

$$\begin{aligned} w_{t+1} &= y - \left(G_t + \frac{1}{2c^\top s} (w_t c^\top + c w_t^\top) \right) s \\ &= w_t - \frac{1}{2} w_t - \frac{w_t^\top s}{2c^\top s} c \\ &= \frac{1}{2} \left(w_t - \frac{w_t^\top s}{c^\top s} c \right). \end{aligned}$$

よって

$$w_{t+1} = P w_t, \quad P := \frac{1}{2} \left(I - \frac{cs^\top}{c^\top s} \right).$$

行列 $cs^\top/c^\top s$ はランク 1 で固有値は $1, 0, \dots, 0$ です。よって P は固有値 0 を一つ持ち、残りはすべて $1/2$ となります。特にスペクトル半径は $1/2 < 1$ であるので、次のように級数が収束します。

$$\begin{aligned} \sum_{t=0}^{\infty} w_t &= \sum_{t=0}^{\infty} P^t (y - Bs) & (w_0 = y - Bs) \\ &= (I - P)^{-1} (y - Bs) \\ &= 2 \left(I - \frac{1}{2} \frac{cs^\top}{c^\top s} \right) (y - Bs). & (\text{definition of } P) \end{aligned}$$

最後の式は次から導かれることに注意してください。

$$2(I - P) \left(I - \frac{1}{2} \frac{cs^\top}{c^\top s} \right) = \left(I + \frac{cs^\top}{c^\top s} \right) \left(I - \frac{1}{2} \frac{cs^\top}{c^\top s} \right) = I.$$

よって

$$\begin{aligned}
\lim_{t \rightarrow \infty} G_t &= B + \frac{1}{2c^\top s} \sum_{t=0}^{\infty} (w_t c^\top + c w_t^\top) \\
&= B + \left(\sum_{t=0}^{\infty} w_t \right) \frac{c^\top}{2c^\top s} + \frac{c}{2c^\top s} \left(\sum_{t=0}^{\infty} w_t \right)^\top \\
&= B + 2 \left(I - \frac{1}{2} \frac{cs^\top}{c^\top s} \right) (y - Bs) \frac{c^\top}{2c^\top s} + \frac{c}{2c^\top s} 2(y - Bs)^\top \left(I - \frac{1}{2} \frac{sc^\top}{c^\top s} \right) \\
&= B + \frac{(y - Bs)c^\top + c(y - Bs)^\top}{c^\top s} - \frac{(y - Bs)^\top s}{(c^\top s)^2} cc^\top \\
&= C_\infty.
\end{aligned}$$

これで偶数番目の部分列 $\{C_{2t}\}_{t=0}^\infty$ が C_∞ に収束することが示されました。
次に奇数番目の部分列について、次の式が成立しています。

$$C_{2t+1} = G_t + \frac{w_t c^\top}{c^\top s}.$$

$G_t \rightarrow C_\infty$ であり、また $\|w_t\| \rightarrow 0$ が P のスペクトル半径が 1 未満であることから従うため、

$$C_{2t+1} \rightarrow C_\infty.$$

従って、部分列 $\{C_{2t}\}_{t=0}^\infty$ と $\{C_{2t+1}\}_{t=0}^\infty$ はどちらも C_∞ に収束し、証明が完了します。 □

$c = s$ のとき、 C_∞ の一般式は標準的な PSB 更新則を導きます。

$$\bar{B}_{\text{PSB}} = B + \frac{(y - Bs)s^\top + s(y - Bs)^\top}{s^\top s} - \frac{(y - Bs)^\top s}{(s^\top s)^2} ss^\top.$$

0.1.4 Davidon – Fletcher – Powell (DFP) 更新

Davidon – Fletcher – Powell (DFP) 更新 [9] も古典的な準ニュートン更新則です。更新則は次で与えられます。

$$\bar{B}_{\text{DFP}} = \left(I - \frac{ys^\top}{y^\top s} \right) B \left(I - \frac{sy^\top}{y^\top s} \right) + \frac{yy^\top}{y^\top s}.$$

導出 先に述べた PSB 更新では $c = s$ としましたが、別の c を選ぶことも可能です。具体的には $c = y$ を代入すると次のように DFP 更新が得られます。

$$\bar{B}_{\text{DFP}} = B + \frac{(y - Bs)y^\top + y(y - Bs)^\top}{y^\top s} - \frac{(y - Bs)^\top s}{(y^\top s)^2} yy^\top.$$

なお、DFP 更新には他にも導出方法が存在し、それらの一部は、次の BFGS 更新における導出の双対版として理解することもできます。

0.1.5 Broyden – Fletcher – Goldfarb – Shanno (BFGS) 更新

Broyden – Fletcher – Goldfarb – Shanno (BFGS) 更新は最も広く使われる準ニュートン法の一つです。更新則は次で与えられます。

$$\bar{B}_{\text{BFGS}} = B - \frac{Bss^\top B}{s^\top Bs} + \frac{yy^\top}{y^\top s}$$

双対による導出 この更新は DFP 更新の双対を考えることで導出できます。後で示すように、 B に対する BFGS 更新は H に対する DFP 更新と同じ形式となっています。

KL ダイバージェンス最小化による導出 KL ダイバージェンスとは、行列間の近さを測る一種の非対称な尺度です。正定値行列 $P, Q \in \mathbb{R}^{n \times n}$ に対して、次で定義されます。

$$\text{KL}(P, Q) := \text{tr}(PQ^{-1}) - \log \det(PQ^{-1}) - n.$$

行列 $T \in \mathbb{R}^{n \times n}$ を任意の正則行列とします。tr は 2 つの行列の積に対して可換性を持つため、KL ダイバージェンスは次の不変性を持ちます。

$$\begin{aligned} \text{KL}(TPT^\top, TQT^\top) &= \text{tr}(TPT^\top(TQT^\top)^{-1}) - \log \det(TPT^\top(TQT^\top)^{-1}) - n \\ &= \text{tr}(PQ^{-1}T^{-1}T) - \log(\det(T)\det(PQ^{-1})\det(T^{-1})) - n \\ &= \text{tr}(PQ^{-1}) - \log \det(PQ^{-1}) - n \\ &= \text{KL}(P, Q). \end{aligned}$$

ここで、BFGS 更新は次の KL ダイバージェンス最小化問題の解として得られることが知られています。

$$\begin{aligned} &\underset{\bar{B} \succ 0}{\text{minimize}} && \text{KL}(\bar{B}, B) \\ &\text{subject to} && \bar{B}s = y. \end{aligned}$$

Proposition 4 ([12, Section 7.2.4]). $B \succ 0$ を正定値対称行列とする。このとき、上記の最適化問題の解は BFGS 更新で与えられる。

Proof. B が正定値対称行列であることに注意して、まず、次のように定義します。

$$s' := B^{\frac{1}{2}}s, \quad y' := B^{-\frac{1}{2}}y, \quad B' := B^{-\frac{1}{2}}\bar{B}B^{-\frac{1}{2}}.$$

すると、最適化問題は次のように書き直せます。

$$\begin{aligned} &\underset{B' \succ 0}{\text{minimize}} && \text{KL}(B', I) \\ &\text{subject to} && B's' = y'. \end{aligned}$$

ただし、KL ダイバージェンスの不変性より、次が成り立つことを用いました。

$$\text{KL}(\bar{B}, B) = \text{KL}(B^{-\frac{1}{2}}\bar{B}B^{-\frac{1}{2}}, B^{-\frac{1}{2}}BB^{-\frac{1}{2}}) = \text{KL}(B', I)$$

なお、本最適化問題において $B' \succ 0$ という制約は自動的に対称性を含むため、 $B' = B'^\top$ を制約として陽に課しても解は変わりません。

この問題の解を、ラグランジュの未定乗数法を用いて求めます。ラグランジュ乗数 $\lambda \in \mathbb{R}^n$ および $\Lambda \in \mathbb{R}^{n \times n}$ を用いて、ラグランジアンを次のように定義します。

$$\mathcal{L}(B', \lambda, \Lambda) = \text{tr}(B') - \log \det(B') - n + 2\lambda^\top (B's' - y') + \text{tr}(\Lambda(B' - B'^\top)).$$

一般に、行列微分の公式として、 $X \succ 0$ に対して、 $\log \det(X)$ の微分が $X^{-\top}$ かつ、 $\text{tr}(AX)$ の微分が $A^\top$ となります。KKT 条件のうち停留性に関する条件は、 B' で微分し、 $B' = B'^\top$ を用いることで次のように書けます。

$$I - B'^{-\top} + 2\lambda s'^\top + \Lambda^\top - \Lambda = 0.$$

この式とその転置を加えて 2 で割り、再び $B' = B'^\top$ を用いると次を得る。

$$B'^{-1} = I + \lambda s'^\top + s' \lambda^\top.$$

制約条件 $B's' = y'$ より $B'^{-1}y' = s'$ であるから、上式に右から y' を掛けた式と、さらに左から $y'^\top$ を掛けた式はそれぞれ、次のようになる。

$$\begin{aligned} s' &= y' + (s'^\top y')\lambda + (\lambda^\top y')s' \\ y'^\top s' &= y'^\top y' + (s'^\top y')(y'^\top \lambda) + (\lambda^\top y')(y'^\top s'). \end{aligned}$$

第2式より

$$\lambda^\top y' = \frac{y'^\top s' - y'^\top y'}{2(s'^\top y')}.$$

これを第1式に代入すると、

$$\lambda = \frac{s' - y'}{s'^\top y'} - \frac{\lambda^\top y'}{s'^\top y'} s' = \frac{s'^\top y' + y'^\top y'}{2(s'^\top y')^2} s' - \frac{1}{s'^\top y'} y'.$$

この λ を B'^{-1} の表式に代入して整理すると、

$$\begin{aligned} B'^{-1} &= I + 2 \frac{s'^\top y' + y'^\top y'}{2(s'^\top y')^2} (s' s'^\top) - \frac{1}{s'^\top y'} (y' s'^\top + s' y'^\top) \\ &= \left(I - \frac{s' y'^\top}{s'^\top y'} \right) \left(I - \frac{y' s'^\top}{s'^\top y'} \right) + \frac{s' s'^\top}{s'^\top y'}. \end{aligned}$$

最後に $B' = B^{-\frac{1}{2}} \bar{B} B^{-\frac{1}{2}}$ より、 $\bar{B} = B^{\frac{1}{2}} B' B^{\frac{1}{2}}$ であるため、 $\bar{B}^{-1}$ を計算すると、

$$\begin{aligned} \bar{B}^{-1} &= B^{-\frac{1}{2}} B'^{-1} B^{-\frac{1}{2}} \\ &= B^{-\frac{1}{2}} \left(I - \frac{s' y'^\top}{s'^\top y'} \right) \left(I - \frac{y' s'^\top}{s'^\top y'} \right) B^{-\frac{1}{2}} + \frac{(B^{-\frac{1}{2}} s') (B^{-\frac{1}{2}} s')^\top}{s'^\top y'} \\ &= B^{-\frac{1}{2}} \left(I - \frac{B^{\frac{1}{2}} s y^\top B^{-\frac{1}{2}}}{s^\top y} \right) \left(I - \frac{B^{-\frac{1}{2}} y s^\top B^{\frac{1}{2}}}{s^\top y} \right) B^{-\frac{1}{2}} + \frac{s s^\top}{s^\top y} \\ &= \left(I - \frac{s y^\top}{y^\top s} \right) B^{-1} \left(I - \frac{y s^\top}{y^\top s} \right) + \frac{s s^\top}{y^\top s}. \end{aligned}$$

後述の通り、これは確かに BFGS 更新の逆行列の公式であるため、証明が完了します。 □

更なる詳細については [5, 6] をご参照ください。 [こちらのスライド](#) も参考になります。

0.2 BFGS 更新の詳細

本小節では BFGS 更新に注目し、その公式の詳細な導出を示します。BFGS 更新は実用上最も成功した準ニュートン更新則の一つとして知られています。BFGS 更新は次で与えられていたことを再掲しておきます。

$$B_{k+1} = B_k - \frac{B_k s_k s_k^\top B_k}{s_k^\top B_k s_k} + \frac{y_k y_k^\top}{y_k^\top s_k}.$$

0.2.1 逆更新の公式

BFGS 更新の逆行列 $H_k := B_k^{-1}$ は次式で与えられます。

$$H_{k+1} = \left(I - \frac{s_k y_k^\top}{y_k^\top s_k} \right) H_k \left(I - \frac{y_k s_k^\top}{y_k^\top s_k} \right) + \frac{s_k s_k^\top}{y_k^\top s_k}.$$

なお、この BFGS 更新における H_{k+1} の公式は、DFP 更新における B_{k+1} の形式と同じであることを注意してください。これらは双対の関係にあります。以下では、この式が確かに BFGS 更新の逆行列を与えることを示します。

Proposition 5. 行列 H_{k+1} は B_{k+1} の逆行列である。

Proof. BFGS 更新は次の簡潔なランク 2 の形に書き直せます。

$$B_{k+1} = B_k + U C V^\top.$$

ここで

$$U = [B_k s_k \quad y_k], \quad C = \begin{pmatrix} -\frac{1}{s_k^\top B_k s_k} & 0 \\ 0 & \frac{1}{y_k^\top s_k} \end{pmatrix}, \quad V = [B_k s_k \quad y_k]$$

です。実際、次の式が成り立ちます。

$$UCV^\top = \begin{bmatrix} -\frac{B_k s_k}{s_k^\top B_k s_k} & \frac{y_k}{y_k^\top s_k} \end{bmatrix} \begin{bmatrix} s_k^\top B_k \\ y_k^\top \end{bmatrix} = -\frac{B_k s_k s_k^\top B_k}{s_k^\top B_k s_k} + \frac{y_k y_k^\top}{y_k^\top s_k}.$$

Sherman – Morrison – Woodbury の恒等式より、 H_{k+1} を次のように計算できます。

$$\begin{aligned} H_{k+1} &= (B_k + UCV^\top)^{-1} \\ &= B_k^{-1} - B_k^{-1}U \left(C^{-1} + V^\top B_k^{-1}U \right)^{-1} V^\top B_k^{-1} \\ &= H_k - [s_k \quad H_k y_k] \left(\begin{pmatrix} -s_k^\top B_k s_k & 0 \\ 0 & y_k^\top s_k \end{pmatrix} + \begin{pmatrix} s_k^\top B_k s_k & s_k^\top y_k \\ y_k^\top s_k & y_k^\top H_k y_k \end{pmatrix} \right)^{-1} \begin{bmatrix} s_k^\top \\ y_k^\top H_k \end{bmatrix} \\ &= H_k - [s_k \quad H_k y_k] \begin{pmatrix} 0 & y_k^\top s_k \\ y_k^\top s_k & y_k^\top H_k y_k + y_k^\top s_k \end{pmatrix}^{-1} \begin{bmatrix} s_k^\top \\ y_k^\top H_k \end{bmatrix} \\ &= H_k - [s_k \quad H_k y_k] \left(-\frac{1}{(y_k^\top s_k)^2} \begin{pmatrix} y_k^\top H_k y_k + y_k^\top s_k & -y_k^\top s_k \\ -y_k^\top s_k & 0 \end{pmatrix} \right) \begin{bmatrix} s_k^\top \\ y_k^\top H_k \end{bmatrix} \\ &= H_k + \frac{1}{(y_k^\top s_k)^2} [s_k \quad H_k y_k] \begin{pmatrix} y_k^\top H_k y_k + y_k^\top s_k & -y_k^\top s_k \\ -y_k^\top s_k & 0 \end{pmatrix} \begin{bmatrix} s_k^\top \\ y_k^\top H_k \end{bmatrix} \\ &= H_k + \frac{1}{(y_k^\top s_k)^2} \left((y_k^\top H_k y_k + y_k^\top s_k) s_k s_k^\top - (y_k^\top s_k)(s_k y_k^\top H_k + H_k y_k s_k^\top) \right) \\ &= \left(I - \frac{s_k y_k^\top}{y_k^\top s_k} \right) H_k \left(I - \frac{y_k s_k^\top}{y_k^\top s_k} \right) + \frac{s_k s_k^\top}{y_k^\top s_k}. \end{aligned}$$

を得ます。 □

0.2.2 BFGS 更新の正定性

BFGS 更新の重要な性質として、現在の近似 B_k が正定値で曲率条件 $y_k^\top s_k > 0$ が成り立つなら、更新後の近似 B_{k+1} も正定値であることが保証されます。

Proposition 6. B_k が正定値で $y_k^\top s_k > 0$ が成り立つなら、 B_{k+1} も正定値である。

Proof. 仮定より B_k とその逆行列 H_k は正定値です。任意の非零ベクトル $v \in \mathbb{R}^n$ に対して

$$v^\top H_{k+1} v = v^\top \left(I - \frac{s_k y_k^\top}{y_k^\top s_k} \right) H_k \left(I - \frac{y_k s_k^\top}{y_k^\top s_k} \right) v + v^\top \frac{s_k s_k^\top}{y_k^\top s_k} v \geq 0 + \frac{(s_k^\top v)^2}{y_k^\top s_k} > 0.$$

ここで第1項は H_k が正定値であるため非負であり、第2項は曲率条件 $y_k^\top s_k > 0$ により正です。よって H_{k+1} は正定値であり、その逆行列 $B_{k+1} = H_{k+1}^{-1}$ も正定値であることが分かります。 □

0.2.3 BFGS 更新のトレースと行列式の公式

更新行列の固有値挙動の解析に有用な、BFGS 更新のトレースと行列式の公式も示しておきます。対称行列においては、これらはそれぞれ固有値の総和と積に対応しています。従ってトレースと行列式が有界なら、固有値自体も有界に保たれると期待できます。これは μ -強凸性や L -平滑性など、目的関数のヘッセ行列固有値に関する仮定と密接に関係するものとなっています。

トレースの公式 BFGS 更新後の行列のトレースは、次のような明示的な公式で与えられます。

Proposition 7 ([9, eq. 6.44]). $B_+ = B - \frac{Bss^\top B}{s^\top Bs} + \frac{yy^\top}{y^\top s}$ を BFGS 更新とする。このとき

$$\text{tr}(B_+) = \text{tr}(B) - \frac{\|Bs\|^2}{s^\top Bs} + \frac{\|y\|^2}{y^\top s}$$

が成り立つ。

Proof. BFGS 更新にトレースを適用すると

$$\text{tr}(B_+) = \text{tr}(B) - \text{tr}\left(\frac{Bss^\top B}{s^\top Bs}\right) + \text{tr}\left(\frac{yy^\top}{y^\top s}\right).$$

第 2 項について

$$\text{tr}\left(\frac{Bss^\top B}{s^\top Bs}\right) = \frac{1}{s^\top Bs} \text{tr}((Bs)(Bs)^\top) = \frac{\|Bs\|^2}{s^\top Bs}.$$

第 3 項について

$$\text{tr}\left(\frac{yy^\top}{y^\top s}\right) = \frac{1}{y^\top s} \text{tr}(yy^\top) = \frac{\|y\|^2}{y^\top s}.$$

以上より所望の式が得られます。 □

行列式の公式 BFGS 更新後の行列式も閉形式で与えられます。

Proposition 8 ([9, eq. 6.45]). $B_+ = B - \frac{Bss^\top B}{s^\top Bs} + \frac{yy^\top}{y^\top s}$ を BFGS 更新とし、 B が正則であるとする。このとき

$$\det(B_+) = \det(B) \frac{y^\top s}{s^\top Bs}$$

が成り立つ。

Proof. [行列式補題](#)より、BFGS 更新のランク 2 表現を思い出すと、 U, C, V は次を満たします。

$$\det(B_{k+1}) = \det(B_k + UCV^\top) = \det(B_k) \det(C) \det(C^{-1} + V^\top B_k^{-1} U).$$

ここで I_2 は 2×2 の単位行列です。 $U = V = \begin{bmatrix} B_k s_k & y_k \end{bmatrix}$ なので

$$V^\top B_k^{-1} U = \begin{bmatrix} s_k^\top B_k s_k & s_k^\top y_k \\ y_k^\top s_k & y_k^\top B_k^{-1} y_k \end{bmatrix},$$

よって

$$C^{-1} + V^\top B_k^{-1} U = \begin{bmatrix} -s_k^\top B_k s_k & 0 \\ 0 & y_k^\top s_k \end{bmatrix} + \begin{bmatrix} s_k^\top B_k s_k & s_k^\top y_k \\ y_k^\top s_k & y_k^\top B_k^{-1} y_k \end{bmatrix} = \begin{bmatrix} 0 & s_k^\top y_k \\ y_k^\top s_k & y_k^\top B_k^{-1} y_k \end{bmatrix}.$$

以上を合わせると

$$\det(B_{k+1}) = \det(B_k) \left(-\frac{1}{s_k^\top B_k s_k} \cdot \frac{1}{y_k^\top s_k} \right) \left(-(s_k^\top y_k)(y_k^\top s_k) \right) = \det(B_k) \frac{y_k^\top s_k}{s_k^\top B_k s_k},$$

を得ます。以上で、証明が完了します。 □

0.3 BFGS と DFP の比較

これまで何度か言及したように、BFGS と DFP は双対関係にあります。しかし、実際の最適化問題に適用すると実用上の効率は大きく異なることが知られています。Powell による解析 [10] では、単純な二次元二次関数に対する両手法の挙動を調べて、この非対称性を検討しました。漸近的には同程度に振る舞うと示唆されることが多い両手法について、Powell はその実用上の効率が大きく異なること、特に近似ヘッセ行列が真のヘッセ行列から遠い場合に差が顕著であることを明らかにしました。ここでは、その数値実験を再現します。

λ_1	BFGS	DFP
0.001	4	3
0.01	5	3
0.1	6	4
1	1	1
10	8	16
100	10	107
1000	12	1006
10000	15	9987

Table 1: 初期固有値 λ_1 に対する BFGS と DFP の収束比較。

0.3.1 問題設定

Powell の問題設定に従い、次の二次関数を考えます。

$$f(x, y) = \frac{1}{2}(x^2 + y^2).$$

この実験で最も大切なことは、初期ヘッセ行列 B_0 の選び方です。本来、この関数のヘッセ行列は単位行列ですが、ここではあえて大幅に誤った近似ヘッセ行列を用いることで、そのような誤りに対する耐性や、その修正能力を測ることを目的としています。具体的には、初期のヘッセ近似 B_0 が固有値 1 と λ_1 を持つように選びました。 λ_1 は初期近似の誤差の程度を表しています。また、BFGS と DFP のどちらも各反復で固定ステップサイズ $\alpha_k = 1$ を用いました。

初期点 x_0 は次のように選びました。

$$\theta = \arctan(\sqrt{\lambda_1}), \quad x_0 = \begin{bmatrix} \cos(\theta) \\ \sin(\theta) \end{bmatrix}.$$

これは Powell の元の解析に沿ったものです。この選択の詳細は [10] を参照してください。

反復は現在点のノルムが初期ノルムに対する許容値を下回るまで続けました。そして、各 λ_1 に対して収束に要する反復回数を記録しました。

0.3.2 数値結果

数値結果を Table 1 に示します。これは Powell の元論文の表と部分的に一致しています。収束挙動は初期固有値 λ_1 に強く依存することが分かります。

Figure 1 と Figure 2 は特定の λ_1 に対する反復軌跡を示しています。これらの図は、同一の初期点から最小点 (原点) へ向かう二つの手法の進み方を可視化し、収束速度と経路の違いを明確に示しています。

0.3.3 解析と議論

数値結果は BFGS と DFP の間に顕著な非対称性があることを示しています。 $\lambda_1 > 1$ のとき、すなわち初期ヘッセ近似が真の曲率を過大評価する場合、BFGS は大幅に高い効率を示しました。一方で、 $\lambda_1 < 1$ のとき、すなわち初期ヘッセ近似が真の曲率を過小評価する場合には、DFP は BFGS よりわずかに良い性能を示しましたが、その差は非常に小さいものでした。この傾向の逆転は理論的な対称性から予測されるものですが、その差の大小は注目に値します。

ヘッセ行列の補正における非対称性 両者の性能の非対称性は、誤った固有値を補正する仕方の根本的な違いに起因します。大事な考察として、過大な固有値の補正が過小な固有値の補正よりも重要であることが挙げられます。

ヘッセ固有値が過大評価されると、アルゴリズムは過度に保守的なステップを取り、最適化の進みが遅くなります。この誤差を補正するには、更新則が大きな固有値を 1 へ縮小する必要があります。BFGS 更新はこのようなタスクには強い効果を発揮しますが、DFP 更新は苦手です。




Figure 1: $\lambda_1 = 100$ における BFGS と DFP の反復軌跡。BFGS は 10 回で収束する一方、DFP は 107 回を要し、固有値誤差が大きい場合に BFGS が優位であることを示しています。

一方で、ヘッセ固有値が過小評価されると、アルゴリズムは大胆なステップを取りますが、その過小評価は自動で修正されやすいです。新しい点での勾配計算が近似の改善を促す為、このような過小評価の補正は本質的に容易で、必要な反復回数も少なくて済みます。

このような差異が、BFGS 更新と DFP 更新の性能の非対称性を生み出していると考えることが出来ます。

0.4 記憶制限 BFGS (L-BFGS)

以下では、準ニュートン法を大規模最適化問題へ拡張する際に重要となる、記憶制限準ニュートン法について説明します。通常の準ニュートン法では、近似ヘッセ行列 B_k またはその逆行列 H_k を密行列として陽に保存・更新するため、 n 変数に対して $\mathcal{O}(n^2)$ のメモリを要します。一方で、記憶制限準ニュートン法では、最新の m 組のベクトルペア $\{(s_i, y_i)\}$ という限られた情報のみを保持して、その情報だけから近似ヘッセ行列に関する計算を行います。この工夫により空間計算量は $\mathcal{O}(nm)$ に減少し、 m が小さな定数 (通常は $m \leq 10$) のとき大幅な改善となります。

特に、BFGS 更新の記憶制限版である L-BFGS 法 [7] は、その代表的な手法です。この BFGS 更新の場合に注目し、限られた情報だけを用いて準ニュートン方向 $d_k = -H_k g_k$ を空間計算量・時間計算量の両面で効率的に計算する方法を示します。

本小節では次の有限長の行列の列を扱います。

$$H_0, H_1, \dots, H_m.$$

ここで H_ℓ は初期行列 H_0 に対して ℓ 回の BFGS 更新を適用して得られる逆ヘッセ近似を表します。

0.4.1 逆行列のコンパクト表現

保存されたベクトルペア $\{(s_i, y_i)\}_{i=0}^{m-1}$ を用いて、次を定義します。

$$\rho_i = \frac{1}{y_i^\top s_i}, \quad V_i = I - \rho_i y_i s_i^\top.$$

このとき、 $i = 0, \dots, m-1$ に対して、BFGS 更新の逆行列は次のように表されます。

$$H_{i+1} = V_i^\top H_i V_i + \rho_i s_i s_i^\top.$$




Figure 2: $\lambda_1 = 0.1$ における BFGS と DFP の反復軌跡。どちらも素早く収束し、DFP が BFGS よりわずかに速くなっています。

この関係を再帰的に展開すると次のコンパクト表現が得られます。

$$H_m = V_{m-1}^\top \cdots V_0^\top H_0 V_0 \cdots V_{m-1} + \sum_{j=0}^{m-1} (V_{m-1}^\top \cdots V_{j+1}^\top) \rho_j s_j s_j^\top (V_{j+1} \cdots V_{m-1}).$$

ここで H_0 は選ばれた初期逆ヘッセ近似であり、通常はスケールされた単位行列です。

0.4.2 二重ループ再帰

準ニュートン法では、逆行列 H_m と与えられたベクトル $q \in \mathbb{R}^n$ に対して $r = H_m q$ が効率的に計算できることが、アルゴリズムにおいて重要です。この計算は長さ m の短いループを二回回すだけで実行でき、L-BFGS の two-loop recursion と呼ばれるアルゴリズムとして知られています [9, Algorithm 7.4]。このアルゴリズムは $\mathcal{O}(nm)$ の時間・空間計算量を要します。

Algorithm 1: L-BFGS Two-Loop Recursion for $r = H_m q$

Input: q , stored pairs $\{(s_i, y_i)\}_{i=0}^{m-1}$, initial matrix H_0
Output: $r = H_m q$

```

1 for  $i = m-1, m-2, \dots, 0$  do
2    $\rho_i \leftarrow 1/(y_i^\top s_i)$ 
3    $\alpha_i \leftarrow \rho_i s_i^\top q$ 
4    $q \leftarrow q - \alpha_i y_i$ 
5 end
6  $r \leftarrow H_0 q$ 
7 for  $i = 0, \dots, m-1$  do
8    $\beta_i \leftarrow \rho_i y_i^\top r$ 
9    $r \leftarrow r + s_i(\alpha_i - \beta_i)$ 
10 end
11 return  $r$ 
```

この二重ループ再帰の出力が確かに $r = H_m q$ を計算していることを、以下では確認します。

Proposition 9. 二重ループ再帰アルゴリズムの出力は $r = H_m q$ を満たす。

Proof. アルゴリズムの1つ目のループ ($i = m-1, m-2, \dots, 0$) では、入力ベクトル $q^{(m)} := q$ から次を計算する。

$$\alpha_i := \rho_i s_i^\top q^{(i+1)}, \quad q^{(i)} := q^{(i+1)} - \alpha_i y_i.$$

α_i の定義を代入し、コンパクト表現における V_i の定義を用いると

$$q^{(i)} = q^{(i+1)} - \rho_i \left(s_i^\top q^{(i+1)} \right) y_i = \left(I - \rho_i y_i s_i^\top \right) q^{(i+1)} = V_i q^{(i+1)}.$$

よってすべての $i = 0, 1, \dots, m-1$ に対して、次が得られます。

$$q^{(i)} = V_i V_{i+1} \cdots V_{m-1} q.$$

次にアルゴリズムは H_0 を適用します。

$$r^{(0)} = H_0 q^{(0)} = H_0 V_0 V_1 \cdots V_{m-1} q.$$

続いて、 $i = 0, 1, \dots, m-1$ に対して、二つ目のループは次を計算します。

$$\beta_i = \rho_i y_i^\top r^{(i)}, \quad r^{(i+1)} = r^{(i)} + s_i (\alpha_i - \beta_i).$$

$\alpha_i, \beta_i, q^{(i+1)}$ の定義を代入すると

$$\begin{aligned} r^{(i+1)} &= r^{(i)} + \rho_i s_i s_i^\top (V_{i+1} V_{i+2} \cdots V_{m-1}) q - \rho_i s_i y_i^\top r^{(i)} \\ &= \left(I - \rho_i y_i s_i^\top \right) r^{(i)} + \rho_i s_i s_i^\top (V_{i+1} V_{i+2} \cdots V_{m-1}) q \\ &= V_i^\top r^{(i)} + \rho_i s_i s_i^\top (V_{i+1} V_{i+2} \cdots V_{m-1}) q. \end{aligned}$$

初期値 $r^{(0)} = H_0 q^{(0)}$ からこの関係を再帰的に展開すると

$$r^{(m)} = V_{m-1}^\top \cdots V_0^\top H_0 V_0 \cdots V_{m-1} q + \sum_{j=0}^{m-1} (V_{m-1}^\top \cdots V_{j+1}^\top) \rho_j s_j s_j^\top (V_{j+1} \cdots V_{m-1}) q.$$

これは、 H_m のコンパクト表現を q に適用した式と一致します。よって、アルゴリズムの出力が $r = H_m q$ を満たすことが示され、証明が完了します。 $\square$

従って、この two-loop recursion によって、行列 H_m を陽に構成せずに、ベクトルに対する作用を正確に評価できることがわかります。

0.4.3 初期スケーリング

L-BFGS 法の重要な要素は初期行列 H_0 の選択です。広く使われるのは、単位行列にスケーリングを施したものです。

$$H_0 = \gamma I.$$

ここでスケーリング係数 γ は、例えば次のように選ばれます。

$$\gamma = \frac{s_{m-1}^\top y_{m-1}}{y_{m-1}^\top y_{m-1}}.$$

この選択は次の議論によって正当化できます [7, 11]。目的関数 f が二回連続微分可能であると仮定し、最新のステップに沿った平均ヘッセ行列を考えます。

$$\bar{G} = \int_0^1 \nabla^2 f(x + \tau s_{m-1}) d\tau.$$

ここで s_{m-1} は最新の x の変位を表しており、次を満たします。

$$y_{m-1} = \nabla f(x + s_{m-1}) - \nabla f(x) = \bar{G} s_{m-1}.$$

この関係を用いるとスケーリング係数は次のように書けます。

$$\frac{s_{m-1}^\top y_{m-1}}{y_{m-1}^\top y_{m-1}} = \frac{(\bar{G}^{1/2} s_{m-1})^\top (\bar{G}^{1/2} s_{m-1})}{(\bar{G}^{1/2} s_{m-1})^\top \bar{G} (\bar{G}^{1/2} s_{m-1})}.$$

これは、ベクトル $\bar{G}^{1/2} s_{m-1}$ に関する行列 $\bar{G}$ の Rayleigh 商の逆数です。従って、このスケーリングはこれらの方向に沿った平均逆曲率を大まかに近似しています。

さらにこの γ の選択は Barzilai – Borwein 法の短ステップサイズ [1] と一致しており、L-BFGS の初期化と古典的なステップ長選択戦略の密接な関係を示しています。

References

- [1] Jonathan Barzilai and Jonathan M. Borwein. Two-Point Step Size Gradient Methods. *IMA Journal of Numerical Analysis*, 8(1):141–148, 1988. ISSN 0272-4979. doi: 10.1093/imanum/8.1.141.
- [2] J. E. Dennis and Robert B. Schnabel. *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*. Society for Industrial and Applied Mathematics, 1996. doi: 10.1137/1.9781611971200.
- [3] J. E. Dennis, Jr. and Jorge J. Moré. Quasi-Newton Methods, Motivation and Theory. *SIAM Review*, 19(1):46–89, 1977. ISSN 0036-1445. doi: 10.1137/1019005.
- [4] Robby Haelterman. *Analytical study of the Least Squares Quasi-Newton method for interaction problems*. PhD thesis, 2009.
- [5] Takafumi Kanamori and Atsumi Ohara. A Bregman Extension of quasi-Newton updates II: Convergence and Robustness Properties, 2010.
- [6] Takafumi Kanamori and Atsumi Ohara. A Bregman Extension of quasi-Newton updates I: An Information Geometrical framework, 2010.
- [7] Dong C. Liu and Jorge Nocedal. On the limited memory BFGS method for large scale optimization. *Mathematical Programming*, 45(1):503–528, 1989. ISSN 1436-4646. doi: 10.1007/BF01589116.
- [8] M.J.D. Powell. A New Algorithm for Unconstrained Optimization. In *Nonlinear Programming*, pages 31–65. Academic Press, 1970. doi: 10.1016/B978-0-12-597050-1.50006-3.
- [9] Jorge Nocedal and Stephen J Wright. *Numerical Optimization*. Springer, 1999. ISBN 978-0-387-30303-1. doi: 10.1007/978-0-387-40065-5.
- [10] M. J. D. Powell. How bad are the BFGS and DFP methods when the objective function is quadratic? *Mathematical Programming*, 34(1):34–47, January 1986. ISSN 1436-4646. doi: 10.1007/BF01582161.
- [11] D. F. Shanno and Kang-Hoh Phua. Matrix conditioning and nonlinear optimization. *Mathematical Programming*, 14(1):149–160, December 1978. ISSN 1436-4646. doi: 10.1007/BF01588962.
- [12] 金森 敬文, 鈴木 大慈, 竹内 一郎, and 佐藤 一誠. *機械学習のための連続最適化*. 機械学習プロフェッショナルシリーズ. 講談社サイエンティフィク, 2016. ISBN 978-4-06-152920-5.